

Exemplo — Módulo 1: Fundamentos de Arquitetura AI-First

Disciplina: Arquitetura de Sistemas com IA · Prof. Ahirton Lopes, Ph.D.

Caso de referência: Vitalis Pharma / TrialForge

Este é um exemplo completo e resolvido, usando o mesmo case acompanhado nos vídeos do módulo. Use-o para conferir seu raciocínio depois de terminar a Missão Prática — não como modelo a copiar, já que o seu caso tem componentes e riscos diferentes.

Passo 1 — Diagrama de Referência: TrialForge

- Gateway — autentica a submissão do protocolo (ou da emenda) e valida o formato antes de encaminhar
- Orquestrador — reconhece o tipo de tarefa (gerar ICF, classificar emenda, rotear por criticidade) e decide os próximos passos
- Modelo + Tools/RAG — busca cláusulas regulatórias via RAG e gera o rascunho do documento
- Approval Gate — especialista regulatório revisa e aprova antes de qualquer documento virar oficial
- Observabilidade — registra versão do prompt, tempo de resposta, e se houve edição humana, para auditoria da ANVISA (transversal aos quatro componentes acima)

Passo 2 — Classificação com o Framework de 3 Perguntas

Componente/ Subtarefa	P1: Regra finita?	P2: Erro caro e irreversível?	P3: Muda com contexto?	Classificação
Gateway: validar formato/autenti cação	Sim	—	—	Regra
Extrair o que mudou entre versões do protocolo (tarefa híbrida, parte 1)	Não	Não	Sim	Agente
Classificar tipo de emenda (tarefa híbrida, parte 2)	Sim (critério fixo ANVISA)	—	—	Regra
Gerar rascunho do Termo de	Não	Sim (documento assinado por	Sim	Agente + Approval Gate

Consentimento		participante)		obrigatório
----------------------	--	---------------	--	-------------

Nota sobre a tarefa híbrida: 'processar uma emenda de protocolo' parecia uma tarefa única, mas se decompõe em extração (ambígua, pede agente) e classificação (regra clara da ANVISA). Aplicar o framework na tarefa inteira, sem decompor, levaria à conclusão errada de que ela é 'toda agente' ou 'toda regra'.

Passo 3 — Orçamento de Trade-off por Componente

Componente	Latência	Custo	Precisão	Eixo inegociável
Gateway	Baixa (crítica)	Baixo	N/A	Latência
Orquestrador	Baixa (crítica)	Baixo	Alta	Precisão do roteamento
Modelo + Tools/RAG	Tolerável	Alto se necessário	Alta	Precisão
Approval Gate	Alta tolerância	N/A	N/A	N/A (decisão humana)

Raciocínio: o componente Modelo + Tools/RAG é o único onde vale pagar mais caro e aceitar mais latência em troca de precisão — porque o framework do Passo 2 já classificou a geração do Termo de Consentimento como erro caro e irreversível. Gateway e Orquestrador priorizam latência baixa porque atrasos ali penalizam o sistema inteiro, não só a tarefa específica.

Reflexão final — um sinal de mudança

Sinal de mudança: se a taxa de correção humana no Approval Gate cair de forma consistente abaixo de um patamar baixo por vários meses seguidos, é sinal de que o modelo amadureceu o suficiente pra revisitar o limiar de confiança — candidato a herdar mais autonomia, não a continuar exatamente como está.

Ahirton Lopes · AI Architecture Toolkit — UNIPDS: Arquitetura de Sistemas com IA

Prof. Ahirton Lopes, Ph.D. — GDE AI, Microsoft MVP, Senior Manager