

Atividade 4 - Módulo 4: Padrões de Design AI-Específicos

Disciplina: Arquitetura de Sistemas com IA · Prof. Ahirton Lopes, Ph.D.

Missão Prática #04

Esta atividade fecha o Módulo 4 inteiro: você vai desenhar um Gateway que combina os quatro grupos de padrão vistos ao longo dos cinco vídeos - RAG, roteamento, cache e streaming, e Approval Gate - aplicados a uma tarefa real do seu próprio contexto de trabalho.

Passo 1 - Mapeie os padrões no seu contexto

Escolha uma tarefa real do seu trabalho (ou hipotética, se ainda não tiver uma) que envolva responder perguntas ou processar requisições repetidas. Para essa tarefa, identifique:

RAG - qual dos quatro padrões (Basic, Hybrid Search, Multi-Index, Agentic) sua busca precisaria, e por qual sintoma real (Módulo 4.1).

- Intent-Based Routing - qual seria a intenção da requisição, e pra onde ela deveria ser roteada.
- Model Router - qual modelo, barato ou caro, deveria processar cada intenção, e por quê.
- Semantic Cache - o que seria cache-ável (perguntas repetidas com palavras diferentes) e o que nunca deveria usar cache.
- Approval Gate - o que justificaria escalar pra revisão humana antes de qualquer resposta virar oficial.

Não repita o exemplo do TrialForge nem o exemplo da central de atendimento do vídeo - o exercício é achar esse equivalente no seu próprio contexto.

Passo 2 - Calibre um limiar com dado real

Não assuma um número de limiar de similaridade (Semantic Cache) ou de confiança (RAG / Approval Gate). Teste pares de pergunta parecida e pergunta diferente contra o modelo de embedding que você escolher, e documente o valor efetivamente encontrado - não copie os números do TrialForge (0,825 / 0,667 / 0,643 / limiar 0,75), eles são específicos do nomic-embed-text em português.

Passo 3 - Rode o protótipo

Execute o Gateway na sua máquina (a entrega oficial é em JavaScript, conforme a ementa; a versão Python é só referência) e registre o que aconteceu nos quatro casos: cache miss, cache hit, Approval Gate por síntese obrigatória, e Approval Gate por confiança baixa.

Entrega

Um único arquivo ou repositório contendo: o blueprint preenchido (Passo 1), o limiar calibrado com a evidência que justifica esse valor (Passo 2), e o log da execução do protótipo mostrando os quatro casos (Passo 3).

Dica de execução

Pensa numa central de atendimento qualquer, fora do contexto de estudo clínico: “Qual o horário de funcionamento?” é intenção de rotina, modelo barato, forte candidata a cache. “Cancelar meu contrato” já é intenção que pelo menos merece um Approval Gate antes de qualquer ação real acontecer. O exercício é achar esse equivalente no seu próprio contexto, não repetir o do TrialForge.

Ahirton Lopes · AI Architecture Toolkit - UNIPDS: Arquitetura de Sistemas com IA

Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager