

Exemplo - Módulo 4: Padrões de Design AI-Específicos (resolvido com TrialForge)

Disciplina: Arquitetura de Sistemas com IA · Prof. Ahirton Lopes, Ph.D.

Missão Prática #04 - solução de referência

Sistema: o Gateway único do TrialForge que recebe uma pergunta e decide, em sequência, a intenção (Intent-Based Routing), se já existe resposta em cache (Semantic Cache), qual modelo processa (Model Router) com a cláusula regulatória mais próxima (RAG), e se precisa de revisão humana antes de responder (Approval Gate) - tudo registrado numa trilha de auditoria (Audit Trail).

Passo 1 - Padrões mapeados

- Consulta de rotina sobre cláusula regulatória → Intent-Based Routing: consulta_clausula, roteada pro modelo barato.
- Síntese final do CSR → Intent-Based Routing: sintese_csr, roteada pro modelo caro, nunca usa cache.
- Paráfrase de uma pergunta já respondida → Semantic Cache: reaproveita a resposta, sem chamar o modelo.
- Síntese do CSR → Approval Gate obrigatório, independente de confiança (erro caro e irreversível, Módulo 1.3).
- Consulta com baixa confiança na busca RAG → Approval Gate por Confidence Threshold, mesmo sendo consulta de rotina.

Passo 2 - Calibração com dado real

Par de pergunta: “Quais são as regras de assentimento pra menores nesse estudo?” vs. “O assentimento dos menores de idade é obrigatório nesse estudo?” - similaridade medida: 0,825 - mesma pergunta: sim, bateu no Semantic Cache.

Confiança do RAG na síntese do CSR (pergunta sobre síntese do CSR, não sobre uma cláusula específica; a cláusula mais próxima encontrada no banco foi a de retirada de consentimento): 0,667 - essa requisição já escalava pro Approval Gate de qualquer forma, por ser síntese de CSR, independente do valor de confiança.

Confiança do RAG numa pergunta de tema bem diferente (armazenamento de amostras biológicas, sem cláusula equivalente no banco): 0,633 - abaixo do limiar de confiança (0,7), aciona Approval Gate por Confidence Threshold.

Limiar de Semantic Cache escolhido: 0,75 (entre a paráfrase próxima, ~0,82-0,83, e o intervalo de tema diferente, ~0,63-0,67, com folga, não no ponto exato de corte).

Limiar de Confidence Threshold escolhido: 0,7.

Passo 3 - Log de execução (4 casos)

[Gateway] Requisição: "Quais são as regras de assentimento pra menores nesse estudo?"

[Semantic Cache] MISS (0.000) - segue pro modelo barato

[Confidence Threshold] 0.803 acima do limiar - segue sem Approval Gate

[Audit Trail] status_final: aprovado

[Gateway] Requisição: "O assentimento dos menores de idade é obrigatório nesse estudo?"

[Semantic Cache] HIT (0.825) - resposta reaproveitada, sem chamar o modelo

[Audit Trail] status_final: respondido_via_cache

[Gateway] Requisição: "Preciso da síntese do CSR final desse estudo."

[Model Router] gemma4:latest (caro/capaz)

[Confidence Threshold] Escalando pro Approval Gate - sintese de CSR, gate sempre obrigatorio

[Approval Gate] Aprovado

[Audit Trail] status_final: aprovado

[Gateway] Requisição: "Qual o prazo de armazenamento das amostras biológicas coletadas nesse estudo?"

[Semantic Cache] MISS (0.626) - segue pro modelo

[Confidence Threshold] Escalando pro Approval Gate - confianca abaixo do limiar ($0.633 < 0.7$)

[Approval Gate] Aprovado

[Audit Trail] status_final: aprovado

Nota de curadoria

Repare que a síntese do CSR (terceira requisição) escala pro Approval Gate por dois motivos possíveis: confiança baixa OU ser síntese de CSR. Nesse caso específico a confiança do RAG (0,667) já estava abaixo do limiar de qualquer forma - mas mesmo que estivesse alta, o Approval Gate seria acionado do mesmo jeito, porque síntese de CSR é sempre erro caro e irreversível (Módulo 1.3), independente de confiança. Log gerado rodando o protótipo de verdade contra Ollama local (gemma4:e2b-mlx, gemma4:latest, nomic-embed-text) nesta sessão.

Ahirton Lopes · AI Architecture Toolkit - UNIPDS: Arquitetura de Sistemas com IA

Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager