

Exemplo - Módulo 5: Arquitetura Enterprise (resolvido com TrialForge)

Disciplina: Arquitetura de Sistemas com IA · Prof. Ahirton Lopes, Ph.D.

Missão Prática #05 - solução de referência (fecha a disciplina)

Sistema: o Gateway do Módulo 4.5 estendido com uma cascata de dois tiers reais via Ollama (gemma4:e2b-mlx barato, gemma4:latest caro) e orçamento verificado por estudo, ANTES de qualquer chamada de modelo - a mesma confiança de RAG do Módulo 4.5 decide a escalação de tier, e a síntese de CSR continua com regra fixa pro tier caro (Módulo 1.3).

Passo 1 - Tiers definidos

- Tier 1 (barato) - gemma4:e2b-mlx, ~\$0,001 por chamada, tentado sempre primeiro.
- Tier 2 (caro) - gemma4:latest, ~\$0,01 por chamada, só entra por escalação ou por regra fixa (síntese de CSR).
- Tier 3 (frontier, opcional) - não implementado neste protótipo, só documentado: entraria no mesmo ponto da cascata, mais uma chamada e mais um limiar.

Passo 2 - Calibração com dado real

Pergunta de rotina sobre assentimento de menores (dentro do banco de cláusulas): confiança da busca RAG medida em 0,803 - acima do limiar, Tier 1 resolve sozinho, sem escalar.

Pergunta fora do banco de cláusulas (prazo de validade de exames laboratoriais): confiança medida em 0,648 - abaixo do limiar, escala pro Tier 2 de forma determinística, não por sorte de uma chamada de LLM não-determinística.

Síntese do CSR: confiança medida em 0,667, mas essa requisição já ia direto pro Tier 2 de qualquer forma - regra fixa, independente de confiança, por ser erro caro e irreversível (Módulo 1.3).

Limiar de cascata escolhido: 0,75 - entre a confiança da pergunta dentro do domínio (0,803) e a confiança da pergunta fora do domínio (0,648), com folga, não no ponto exato de corte (Módulo 4.2). Coincide numericamente com o limiar de Semantic Cache do Módulo 4.5 (também 0,75) só por acaso - são decisões diferentes, calibradas contra o mesmo nomic-embed-text.

Passo 3 - Orçamento por tenant

estudo-A: limite 0,05 - folga suficiente pra cobrir as 3 chamadas do estudo com margem. estudo-B: limite 0,005, propositalmente baixo, pra demonstrar bloqueio. Orçamento verificado ANTES de qualquer chamada de modelo, com o custo máximo possível da requisição (Tier 1 + Tier 2 se a intenção não for síntese de CSR; só Tier 2 se for).

Passo 4 - Log de execução (os três comportamentos, 4 chamadas)

[Gateway] Estudo "estudo-A" – requisição: "Quais são as regras de assentimento pra menores nesse estudo?"

[Model Tiering] Tentando Tier 1 (barato) primeiro – confiança da busca: 0.803

[Model Tiering] Confiança 0.803 acima do limiar – Tier 1 resolve, sem escalar.

[Orçamento] Estudo "estudo-A": gasto acumulado 0.0010 / limite 0.05

[Gateway] Estudo "estudo-A" – requisição: "Qual é o prazo de validade dos exames laboratoriais desse estudo?"

[Model Tiering] Tentando Tier 1 (barato) primeiro – confiança da busca: 0.648

[Model Tiering] Confiança 0.648 abaixo do limiar (0.75) – escalando pro Tier 2.

[Orçamento] Estudo "estudo-A": gasto acumulado 0.0120 / limite 0.05

[Gateway] Estudo "estudo-A" – requisição: "Preciso da síntese do CSR final desse estudo."

[Model Tiering] Síntese de CSR – regra fixa, direto pro Tier 2 (caro).

[Approval Gate] Rascunho aguardando aprovação antes de virar oficial... Aprovar? (s/n) s

[Orçamento] Estudo "estudo-A": gasto acumulado 0.0220 / limite 0.05

[Gateway] Estudo "estudo-B" – requisição: "Quais são as regras de assentimento pra menores nesse estudo?"

[Orçamento] BLOQUEADO – estudo "estudo-B" ultrapassaria o limite antes mesmo de chamar o modelo.

Passo 5 - Reflexão final (resolvida)

Neste protótipo, 1 das 3 requisições do estudo-A escalou pro Tier 2 por confiança baixa (33%), além da síntese de CSR que vai direto por regra fixa. Se esse volume de escalação por confiança baixa continuasse crescendo mesmo depois de recalibrar o limiar com mais dado real - por exemplo, se o Tier 2 também começasse a errar sistematicamente um tipo específico de pergunta (perguntas fora do banco de cláusulas atual, mas dentro de um novo tema recorrente) - esse seria o sinal de que vale introduzir um Tier 3: não o volume de escalação isolado, mas o Tier 2 deixando de ser a resposta certa pra esse volume.

Nota de curadoria

Os três comportamentos exigidos aparecem nas 4 chamadas: Tier 1 resolve sozinho (chamada 1), a cascata escala por confiança (chamada 2), a regra fixa de CSR manda direto pro Tier 2 sem depender de confiança (chamada 3, mesmo com confiança 0,667 - corte separado do limiar de cascata), e o bloqueio por orçamento acontece antes de qualquer chamada de modelo (chamada 4, estudo-B). Log gerado rodando o protótipo de verdade contra Ollama local (gemma4:e2b-mlx, gemma4:latest, nomic-embed-text) nesta sessão.

Ahirton Lopes · AI Architecture Toolkit - UNIPDS: Arquitetura de Sistemas com IA

Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager