

Atividade 1 - Módulo 1: Quando Fazer Fine-Tuning (Decision Framework)

Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.

Missão Prática #01

Esta atividade fecha o Módulo 1 inteiro: você vai aplicar, num caso real do seu próprio contexto de trabalho (não um exemplo hipotético), os instrumentos construídos ao longo dos três vídeos: o framework de quatro perguntas, o gate de governança/compliance, a ponderação por AHP (ou score direto), e a estimativa de retorno financeiro.

Passo 1 - Aplique o Framework de Quatro Perguntas ao seu caso

Escolha uma tarefa real do seu trabalho (ou de um projeto que você conhece bem) que hoje usa prompt engineering ou RAG, e que você imagina se beneficiando de fine-tuning. Responda as quatro perguntas do Módulo 1.1, com justificativa:

- P1: É uma tarefa estreita e repetida, ou muda de escopo a cada chamada?
- P2: Prompt engineering e RAG já foram tentados e esgotados, ou ainda dá pra melhorar sem treinar modelo?
- P3: Existe dado histórico suficiente (rótulo real, não sintético) pra treinar?
- P4: A tarefa é estável, ou o comportamento esperado muda com frequência?

Pergunta	Sim / Não	Justificativa	Sinal (verde/vermelho)
P1: Tarefa estreita e repetida?			
P2: Prompt/RAG já esgotados?			
P3: Dado histórico suficiente?			
P4: Tarefa estável?			

Passo 2 - Pondere as perguntas

Duas opções, escolha uma. (a) AHP completo: construa uma matriz de comparação pareada 4x4 na escala de Saaty (1 a 9) e calcule os pesos pelo método da média geométrica das linhas, verificando a Razão de Consistência antes de confiar no resultado. Veja o método aplicado em [decision-framework-tool.js](#). (b) Score direto: atribua um peso de 0 a 1 pra cada pergunta, somando 1 no total, justificando por que alguma pesa mais que as outras. Documente qual caminho escolheu e por quê.

Passo 3 - Estime o retorno financeiro

Não precisa da simulação de Monte Carlo completa: um NPV determinístico simplificado já é entrega válida. Estime: custo aproximado de preparar dataset e treinar (mesmo que grosseiro); economia recorrente esperada rodando fine-tunado em vez do fluxo atual; breakeven

aproximado em meses. Se a única reprovação do seu caso for a Pergunta 3 (dado insuficiente), documente também o valor de esperar: quantos meses até acumular dado suficiente, e por que esperar pode valer mais que decidir agora. Se a reprovação vier de outra pergunta (P1 ou P4, não a P3), documente por que Real Options não se aplica ao seu caso: esse instrumento só serve pra reprovação que se resolve com tempo, exatamente como o Módulo 1.3 mostrou com o caso Amplitude Atendimento ao Cliente. Os valores do case Amplitude Seguros usados ao longo do curso (custo de treino, custo por chamada, volume) são ilustrativos, calibrados só pra dar uma história coerente: aqui você substitui por números reais do seu próprio contexto de trabalho.

Passo 4 - Rode o código com o seu caso

Adapte amplitude-seguros-casos.json (ou crie um arquivo novo no mesmo formato) com os dados dos Passos 1 a 3 do seu próprio caso, e rode decision-framework-tool.js contra ele. A entrega oficial é em JavaScript, conforme a ementa (existe versão equivalente em Python, decision_framework_tool.py, só como material de apoio). Confirme que o resultado impresso bate com sua análise manual dos Passos 1 a 3.

Entrega

- Framework de quatro perguntas preenchido, com justificativa e sinal verde/vermelho por pergunta
- Peso de cada pergunta documentado (AHP ou score direto) e por quê
- Estimativa financeira (custo, economia, breakeven e, se aplicável, valor de esperar ou justificativa de por que Real Options não se aplica ao seu caso)
- Print ou output do código rodando com o seu próprio caso
- Recomendação final: fine-tuning agora, esperar, ou não fazer fine-tuning

Dica de execução

Não use um contexto hipotético. Escolha a tarefa mais recente ou mais relevante do seu trabalho atual: o exercício de decisão fica mais honesto quando você avalia um caso real. Se, ao final, você concluir que sua tarefa não precisa de fine-tuning e prompt ou RAG já resolvem bem, essa também é uma entrega válida: o objetivo não é sempre decidir treinar, é decidir corretamente quando fine-tuning é a resposta certa.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos
Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager