

Exemplo - Módulo 1: Quando Fazer Fine-Tuning (resolvido com Amplitude Seguros)

Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.

Missão Prática #01 - solução de referência

Caso escolhido: Amplitude Auto, extração automatizada de segurado, placa e valor a partir do orçamento de oficina anexado ao sinistro.

Passo 1 - Framework de quatro perguntas

Pergunta	Sim / Não	Justificativa	Sinal
P1: Tarefa estreita e repetida?	Sim	Extração de segurado/placa/valor de orçamento de oficina: mesma tarefa, milhares de vezes, campo de saída sempre igual.	Verde
P2: Prompt/RAG já esgotados?	Sim	RAG contra manual de sinistros já roda em produção há meses; taxa de erro de extração estabilizou em ~8%, sem ganho adicional ajustando prompt.	Verde
P3: Dado histórico suficiente?	Sim	Mais de 3 anos de sinistros de auto processados, schema estável, campo de saída sempre validado por analista humano no passado.	Verde
P4: Tarefa estável?	Sim	Campos exigidos (segurado, placa, valor) não mudaram em 3 anos; regulação de sinistro auto não tem mudança recente prevista.	Verde

As quatro perguntas dão sinal verde, nenhuma reprovação. Isso já indica que o caso é candidato forte a fine-tuning, mas a decisão final ainda depende do peso relativo de cada pergunta e do retorno financeiro, não só do sinal isolado.

Passo 2 - Ponderação via AHP

Caminho escolhido: AHP completo, não score a dedo. Matriz de comparação pareada (escala de Saaty) julgando P3 (dado suficiente) como a restrição mais cara de resolver: se falhar, nenhuma das outras três importa, porque não tem como "decidir" ter mais histórico. Pesos resultantes pelo método da média geométrica das linhas: P1 = 0,141, P2 = 0,141, P3 = 0,455, P4 = 0,263. Razão de Consistência calculada: CR = 0,0038, bem abaixo do limiar de 0,10 de Saaty: julgamento consistente, pesos confiáveis.

Score composto do Amplitude Auto, com os pesos AHP: 0,88. Mas quem aprova o caso não é esse número: são as quatro perguntas passando individualmente o limiar de 0,6 cada uma (P1: 0,90, P2: 0,85, P3: 0,90, P4: 0,85, todas verdes). O score composto é informativo, não o critério de decisão.

Passo 3 - Estimativa financeira

- Custo de preparar dataset + treinar: estimativa conservadora, na faixa de custo de infraestrutura de GPU cloud (LoRA) citada no cheatsheet do Módulo 1.3.
- Economia recorrente: redução de custo por chamada rodando modelo fine-tunado (menor, mais barato) em vez do fluxo atual de RAG contra manual completo.
- NPV/fluxo de caixa descontado: positivo no horizonte de 24 meses.
- Breakeven: mês 10. A partir daí, o custo de treino já foi coberto pela economia recorrente.

Como as quatro perguntas passam (nenhuma reprovação por dado insuficiente), Real Options / valor de esperar não se aplica aqui: esse instrumento só entra quando a única reprovação é a Pergunta 3, caso do Amplitude Saúde Empresarial (ver Módulo 1.3, onde o valor de esperar por 9 meses foi precificado numa árvore binomial com volatilidade derivada do Monte Carlo, algo em torno de R\$ 230, e não um número fixo: varia levemente a cada rodada porque a volatilidade vem da própria simulação).

Passo 4 - Execução do código

Ver decision-framework-tool.js: o caso Amplitude Auto já está declarado em amplitude-seguros-casos.json com a matriz AHP e os parâmetros financeiros usados acima. Rodando node decision-framework-tool.js, o resultado impresso confirma exatamente os números deste documento: score composto 0,88, aprovado, NPV positivo com breakeven no mês 10. Vinte e nove testes automatizados garantem que a lógica de governança, do AHP, do NPV, do Monte Carlo e do Real Options (árvore binomial) bate com o valor esperado antes de confiar no resultado.

Nota de curadoria

Repare que o Amplitude Auto passa nas quatro perguntas com folga, é um caso "fácil" de propósito, pra servir de exemplo de referência limpo. Os dois casos mais interessantes desta disciplina são o Amplitude Saúde Empresarial, que reprova só a Pergunta 3 mas seria aprovado se olhássemos só a média (é ali que o gate-bate-média e o valor de esperar realmente importam), e o Amplitude Atendimento ao Cliente, que reprova em duas perguntas mesmo com score composto mais alto que o de Saúde Empresarial, e não é elegível a Real Options porque a reprovação não é por dado. Ao fazer sua própria atividade, não escolha só o caso fácil: se seu contexto de trabalho tiver um caso como o da Saúde Empresarial ou como o do Atendimento ao Cliente, ele ensina mais sobre como usar o framework de verdade.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos
Prof. Ahirton Lopes, Ph.D. · GDE AI, Microsoft MVP, Senior Manager