

Atividade 2 - Módulo 2: Preparação de Datasets para Fine-Tuning

Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.

Missão Prática #02

Esta atividade fecha o Módulo 2 inteiro: você vai aplicar, num caso real do seu próprio contexto de trabalho (não um exemplo hipotético), os instrumentos construídos ao longo dos dois vídeos: o gate de relevância de dado, o schema canônico, e a deduplicação e balanceamento por fonte.

Passo 1 - Aplique o gate de relevância aos candidatos do seu caso

Liste pelo menos quatro candidatos de fonte de dado do seu contexto de trabalho que poderiam virar exemplo de treino (nem todos precisam passar, é assim que o exercício fica honesto). Para cada um, responda as quatro perguntas do Módulo 2.1:

- Contém o ground truth da tarefa (entrada real + resposta correta observável)?
- Vem do fluxo real de produção, não é exemplo sintético ou hipotético?
- Cobre a variação real de formato que a tarefa tem, não só o caso fácil?
- Passa no crivo de sensibilidade e compliance pra ser usado em treino?

Candidato	Ground truth?	Produção real?	Cobre variação?	Compliance ?	Aceito?

Passo 2 - Declare o schema canônico do seu caso

Defina os quatro campos do Módulo 2.1 pro seu contexto: instrução (a tarefa em linguagem natural, a mesma frase pro caso inteiro), entrada (o texto bruto, sem limpeza), saída (os campos estruturados específicos da sua tarefa, liste quais são), e metadata (o que precisa ficar registrado sobre a origem de cada exemplo: fonte, data, nível de confiança, se passou validação).

Passo 3 - Monte um dataset pequeno e rode dedup + balanceamento

Reúna, ou simule de forma realista se ainda não tiver dado real suficiente, pelo menos quinze exemplos do seu caso, vindos de pelo menos três fontes diferentes. Rode a deduplicação via MinHash + LSH banding (assinatura aproximando Jaccard, candidatos gerados por colisão de banda, refino com Jaccard exato) e o balanceamento por amostragem com temperatura (peso proporcional a n_i^α , $\alpha=0,3$, alocação capacitada pelo método do maior resto) contra esse conjunto. Adapte dataset-cleaning-balancing-tool.js pro seu caso, trocando os templates e listas de entidade pelos do seu próprio contexto. Em dataset pequeno (poucas dezenas de exemplos), é normal o ganho de eficiência do LSH ser menos dramático que os 96,4% vistos

no vídeo; a técnica continua correta, só a economia de comparação fica mais visível em escala maior.

Passo 4 - Implemente em JavaScript

A entrega oficial é o código rodando de verdade contra o seu caso: geração ou coleta do dataset, deduplicação via MinHash+LSH, balanceamento por temperatura, e ao menos a entropia (ou número efetivo de fontes) calculada antes/depois, com pelo menos um teste automatizado confirmando que o método detecta o que deveria detectar (existe versão equivalente em Python, `dataset_cleaning_balancing_tool.py`, só como material de apoio).

Entrega

- Gate de relevância aplicado a pelo menos quatro candidatos, com pelo menos um rejeitado e a justificativa
- Schema canônico declarado com os quatro campos específicos do seu caso
- Dataset de pelo menos quinze exemplos, com resultado de deduplicação e balanceamento antes/depois
- Código funcional em JavaScript (Passo 4), com ao menos um teste automatizado

Dica de execução

Não use um contexto hipotético. Escolha a fonte de dado mais próxima do seu trabalho atual: o exercício de curadoria fica mais honesto quando você avalia candidato real, inclusive os que vão ser rejeitados. Se, ao final, você concluir que sua fonte de dado principal não tem volume suficiente ainda pra treinar nada, essa também é uma entrega válida: o objetivo não é sempre montar um dataset perfeito, é saber identificar o que falta antes de gastar tempo de treino em cima de dado ruim.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos
Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager