

Exemplo - Módulo 2: Preparação de Datasets para Fine-Tuning (resolvido com Amplitude Seguros)

Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.

Missão Prática #02 - solução de referência

Caso escolhido: os dois casos fixos da disciplina, Amplitude Auto (sinistro de colisão) e Amplitude Saúde Empresarial (reembolso médico).

Passo 1 - Gate de relevância aplicado a sete candidatos

Candidato	GT	Prod.	Variação	Compl.	Resultado
Orçamento de oficina	Sim	Sim	Sim	Sim	ACEITO, usado no pipeline
Boletim de ocorrência	Não	Sim	Sim	Sim	Rejeitado, não traz segurado/placa/valor confiável
Foto do veículo danificado	Não	Sim	Não	Sim	Rejeitado, imagem, não par texto entrada/saída
Transcrição da ligação de abertura de sinistro	Sim	Sim	Não	Sim	Rejeitado, estrutura varia demais de atendente pra atendente, não serve de referência de formato
Recibo médico	Sim	Sim	Sim	Sim	ACEITO, usado no pipeline
Prontuário médico completo	Sim	Sim	Sim	Não	Rejeitado, viola minimização de dado da LGPD
Cadastro de beneficiários	Não	Sim	Sim	Sim	Rejeitado, tabela de referência, não par de extração

De sete candidatos plausíveis (seria fácil coletar todos), só dois passam nas quatro perguntas, exatamente os dois que o pipeline de extração usa. Os outros cinco são rejeitados por motivo diferente cada um, o que prova que o gate está discriminando de verdade, não é decoração.

Passo 2 - Schema canônico

- instrução: a tarefa em linguagem natural, mesma frase pro caso inteiro (ex.: "Extraia segurado, placa e valor do orçamento de oficina abaixo")
- entrada: o texto OCR bruto, sem limpeza, exatamente como saiu do documento
- saída: campos estruturados específicos por caso: segurado/placa/valor no Auto; beneficiário/procedimento/valor na Saúde Empresarial
- metadata: caso, fonte (oficina/clínica), confiança do OCR, se passou na validação

Passo 3 - Dataset simulado e resultado de dedup + balanceamento

Dataset simulado: 47 exemplos (28 Amplitude Auto de 4 oficinas, 19 Saúde Empresarial de 3 clínicas), com 3 pares de quase-duplicata plantados de propósito e 2 fontes desbalanceadas (Oficina Estrela em 53,8% do caso Auto, Clínica Vitalis em 61,1% da Saúde Empresarial).

Deduplicação via MinHash (Broder, 1997) + LSH banding: cada exemplo vira uma assinatura de 32 números, dividida em 8 bandas de 4 valores; candidatos que colidem em qualquer banda passam por um refino com Jaccard exato (limiar 0,55). Isso reduz 549 comparações força-bruta pra 20 candidatos (redução de 96,4%), sem perder nenhum dos 3 pares reais: recall perfeito, verificado nos testes. 47 vira 44 exemplos.

Balanceamento via amostragem por temperatura (Raffel et al. 2020, T5; Xue et al. 2021, mT5): peso de cada fonte proporcional a n_i^α , com $\alpha=0,3$ (mesmo valor do mT5). O peso vira contagem inteira pelo método do maior resto (Hamilton/Hare-Niemeyer), com restrição de capacidade: nenhuma fonte é alocada acima do que ela tem disponível. 44 vira 34 exemplos: Oficina Estrela cai de 53,8% pra 40,0% do caso Auto, Clínica Vitalis de 61,1% pra 50,0% da Saúde Empresarial.

Diversidade medida em número: o número efetivo de fontes (exp da entropia de Shannon) sobe de 3,279 pra 3,742 no caso Auto (de 4 fontes reais) e de 2,544 pra 2,814 na Saúde Empresarial (de 3 fontes reais): prova formal de que o balanceamento aumentou a diversidade, não só suposição.

Nota conceitual - shingle e Jaccard, com números reais do nosso dataset

"Shingle" é o nome técnico pra uma janela deslizante de N palavras consecutivas de um texto (Broder, 1997). No nosso pipeline, $N=5$. Pegando um trecho real de um dos orçamentos do dataset, "reparo de lataria e pintura no para-choque dianteiro" (8 palavras), a janela de 5 desliza uma palavra por vez e produz 4 shingles: "reparo de lataria e pintura", "de lataria e pintura no", "lataria e pintura no para-choque", "e pintura no para-choque dianteiro". Cada documento inteiro vira um conjunto desses shingles (dezenas deles, no caso de um orçamento completo); dois documentos que compartilham muitos shingles têm muito texto idêntico em sequência, não só palavras-chave em comum.

A similaridade de Jaccard entre dois documentos é a fração de shingles em comum sobre o total de shingles únicos dos dois: interseção dividida por união. Documentos idênticos têm Jaccard 1,0 (a interseção é a união inteira); documentos sem nenhum shingle em comum têm Jaccard 0,0. O limiar do nosso pipeline é 0,55: acima disso, o par é tratado como quase-duplicata e um dos dois é descartado.

Exemplo real do dataset simulado, com Jaccard calculado à mão: dois orçamentos da Oficina Estrela pro mesmo sinistro (segurado Joaquim Pedro Salgado, placa MNB-3310), um deles com dois erros de OCR ("P1aca" no lugar de "Placa", "veicu1o" no lugar de "veiculo", o número 1 confundido com a letra l). Os dois textos geram 39 shingles cada; 32 são idênticos entre os dois, sobrando 7 exclusivos de cada lado, exatamente os shingles que passam pela palavra com erro de digitação. $Jaccard = 32 / (39+39-32) = 32/46 = 0,6957$, acima do limiar: o par é corretamente marcado como quase-duplicata, sem nenhuma comparação exata palavra por palavra.

Contraste com o par citado na Nota de curadoria logo abaixo: dois orçamentos da mesma Oficina Estrela, mesmo papel timbrado, mas sinistros diferentes (Marcos Vinicius Andrade Pereira vs. Joaquim Pedro Salgado, valores e datas diferentes). $Jaccard = 23/56 = 0,4107$, abaixo do limiar: mesmo cabeçalho, mesmo formato de frase, mesma oficina, mas o pipeline reconhece que são dois sinistros genuinamente diferentes e mantém os dois no dataset. É essa distinção, entre documentos parecidos porque usam o mesmo molde e documentos parecidos porque são a mesma coisa reenviada, que o limiar 0,55 discrimina.

O MinHash aproxima esse mesmo cálculo sem comparar todo par de documentos: cada conjunto de shingles vira uma assinatura de 32 números, e a fração de números iguais entre duas assinaturas estima o Jaccard sem nunca comparar os shingles inteiros de novo. O LSH banding divide essa assinatura em 8 grupos de 4 números e só compara de verdade os pares que colidem em algum grupo, o motivo de 549 comparações força-bruta virarem 20 candidatos (redução de 96,4%) sem perder nenhum dos 3 pares reais de duplicata.

Nota conceitual - amostragem por temperatura, maior resto e entropia, com números reais

Aviso de nomenclatura antes do mecanismo: "temperatura" aqui é o parâmetro estatístico de amostragem por fonte (Raffel et al. 2020, T5; Xue et al. 2021, mT5), diferente da "temperatura" de geração de texto de um LLM (o parâmetro que controla aleatoriedade da resposta, citado de novo lá no Módulo 5.3). Mesma palavra, dois parâmetros sem relação direta: aqui ela controla o quanto o balanceamento se afasta da proporção bruta entre fontes; lá, o quanto a próxima palavra gerada se afasta da escolha mais provável.

O método do maior resto (Hamilton/Hare-Niemeyer), com números reais do caso Auto (Oficina Estrela=14, Auto Center Silva=5, Funilaria Rio Bonito=4, Oficina Nova Aliança=3 exemplos, alvo de 20 depois do balanceamento): cada fonte recebe um peso proporcional a $n_i^{0,3}$, que vira uma quota contínua multiplicando pelo alvo (Estrela 6,555; Auto Center Silva 4,813; Funilaria Rio Bonito 4,502; Nova Aliança 4,129). Cada fonte fica com o piso dessa quota ($6+4+4+4=18$) e as 2 vagas que faltam pra chegar em 20 vão pras fontes com maior resto decimal, Auto Center Silva (0,813) e Estrela (0,555): resultado ingênuo Estrela=7, Auto Center Silva=5, Funilaria Rio Bonito=4, Nova Aliança=4.

Só que a Nova Aliança só tem 3 exemplos reais disponíveis, alocar 4 seria inventar 1 exemplo que não existe. É aqui que entra a restrição de capacidade: o pipeline detecta que a Nova Aliança estouraria (4 maior que 3), fixa ela no teto real de 3, e redistribui a vaga que sobrou entre as 3 fontes restantes, recalculando o peso por temperatura só entre elas com alvo restante de 17. Nessa segunda rodada (Estrela, Auto Center Silva e Funilaria, alvo 17), o maior resto decimal é o da Funilaria (0,822), não o da Estrela (0,022): tentativa Funilaria=5. Só que a Funilaria só tem 4 exemplos reais disponíveis, a mesma restrição de capacidade que já apareceu com a Nova Aliança - fixa Funilaria em 4 e redistribui o alvo restante (13) entre Estrela e Auto Center Silva. A tentativa seguinte dá Auto Center Silva=6, que de novo estoura a capacidade real dela (5): fixa Auto Center Silva em 5 e, com só a Estrela sobrando, ela absorve o alvo restante inteiro. Resultado final real: Estrela=8 (não 7), Auto Center Silva=5, Funilaria Rio Bonito=4, Nova Aliança=3 (não 4): 8/20 é exatamente 40,0%. "Balancear não é inventar exemplo" não é só um slogan: é o motivo exato pelo qual a Estrela termina com 8 em vez dos 7 que a fórmula ingênua daria.

A entropia de Shannon do caso Auto antes do balanceamento (distribuição 53,8%/19,2%/15,4%/11,5%) é $H = -\text{soma}(p \text{ vezes } \ln(p)) = 1,1875$ nats; número efetivo de fontes = e elevado a $H = 3,279$, o dataset original "vale" como se fossem 3,279 fontes igualmente representadas, mesmo tendo 4 fontes reais, porque a Oficina Estrela domina. Depois do balanceamento (40%/25%/20%/15%), H sobe pra 1,3195 nats, número efetivo pra 3,742, mais perto das 4 fontes reais que existem de verdade: prova numérica de que o balanceamento espalhou a representação, não só cortou um número que parecia grande.

Passo 4 - Execução do código

Ver `dataset-cleaning-balancing-tool.js` e `dataset_cleaning_balancing_tool.py`: 16 testes automatizados confirmam, em ambas as linguagens: aproximação do MinHash contra o Jaccard exato, recall perfeito do LSH, alocação capacitada nunca excedendo a fonte real, e entropia sempre subindo (nunca descendo) quando a distribuição é suavizada.

Nota de curadoria

Repare que o detector não marca como duplicata dois orçamentos da mesma Oficina Estrela com sinistro diferente, mesmo os dois usando o mesmo papel timbrado: a similaridade fica em torno de 0,4, bem abaixo do limiar de 0,55. Isso é o ponto mais fácil de errar num detector ingênuo: mesmo template não é duplicata. Ao fazer sua própria atividade, teste esse caso de propósito, dois exemplos genuinamente diferentes, mas do mesmo formato de origem, pra confirmar que seu limiar não está rejeitando dado bom. E se a escala do seu caso não justificar MinHash+LSH (poucos exemplos, comparação direta já é rápida o bastante), documentar essa decisão também é análise válida: a técnica formal serve pra quando o volume exige, não é obrigatória em qualquer escala.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos
Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager