

Atividade 5 - Módulo 5: Avaliar Modelos Fine-Tunados

Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.

Missão Prática #05

Esta atividade fecha o Módulo 5 inteiro: vocês vão aplicar, ao próprio contexto de trabalho, o protocolo completo de avaliação de modelo fine-tunado construído ao longo dos quatro vídeos deste módulo, teste retido, comparação A/B contra genérico, teste de estresse, e um checklist de graduação explícito pra decidir se o piloto está pronto pra escalar.

Passo 1 - Construam um conjunto de teste retido de verdade

Peguem um modelo fine-tunado do próprio trabalho de vocês, ou o caso hipotético que já vêm usando desde módulos anteriores. Construam um conjunto de teste retido: exemplos que o modelo nunca viu no treino, com o mesmo formato da tarefa real. Se usarem um gerador determinístico como o `gerarExemplo` desta disciplina, usem índices bem fora da faixa do treino, a mesma técnica do Módulo 5.1. Rodem contra o modelo real e meçam adequação de schema e precisão por campo.

Passo 2 - Comparem contra um modelo genérico

Rodem o mesmo conjunto de teste retido contra um modelo genérico, sem ajuste, mesmo prompt pros dois. Testem duas vezes: sem nenhum hint de formato, e depois com uma instrução explícita pedindo JSON válido sem markdown. Documentem separadamente a taxa de schema válido e a precisão média dos dois testes, a mesma comparação do Módulo 5.2.

Passo 3 - Construam um teste de estresse

Escrevam à mão, não com o gerador determinístico, pelo menos três exemplos que variem formato (rótulo diferente, sem símbolo de moeda, texto corrido) ou estrutura (mais de uma entidade no mesmo documento, valor por extenso). Antes de aceitar qualquer queda de precisão como real, investiguem a causa raiz campo a campo: pode ser um bug de comparação, não um erro de compreensão, a mesma lição do Módulo 5.3.

Passo 4 - Apliquem o checklist de graduação

A entrega final: definam, ANTES de rodar os testes acima, um checklist de graduação com limiares explícitos, por exemplo baseline mínimo, comparação mínima contra o genérico, e queda máxima aceitável no teste de estresse. Depois de medir, apliquem o checklist e documentem o veredito: o piloto de vocês está pronto pra escalar, ou não, com critério explícito, não intuição. Reaproveitem `veredito-escala-tool.js` como referência de estrutura.

Entrega

- Conjunto de teste retido real, com índices ou fonte fora da faixa de treino, documentado (Passo 1)
- Resultado do A/B contra um modelo genérico, com e sem hint de formato, schema e precisão documentados (Passo 2)
- Pelo menos três exemplos de teste de estresse, construídos à mão, com investigação de causa raiz de qualquer queda (Passo 3)

- Checklist de graduação com limiares definidos antes de medir, e veredito final documentado (Passo 4)
- Reflexão final: o que este protocolo revelou que uma medição única, sem teste retido nem estresse, teria escondido?

Dica de execução

Se não tiverem um modelo fine-tunado publicado no momento de fazer a atividade, simulem os resultados com base num caso hipotético plausível, documentando claramente que são simulados, e apliquem o mesmo rigor de investigar antes de aceitar qualquer número. O valor da atividade está no protocolo, não em ter acesso a um modelo real: concluir, com critério explícito, que um piloto hipotético não está pronto pra escalar também é uma entrega válida.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos
Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager