

## Exemplo - Módulo 5: Avaliar Modelos Fine-Tunados

*Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.*

### Missão Prática #05 - solução de referência

Resolvida com o caso real da Amplitude Seguros: os três casos avaliados pelo framework do Módulo 1.3, usando os números reais medidos nos Módulos 5.1, 5.2, 5.3 e 5.4.

#### Passo 1 - Conjunto de teste retido

Conjunto retido: onze exemplos, seis Amplitude Auto e cinco Saúde Empresarial, gerados por gerarExemplo com offset de índice 5000, bem fora da faixa 0-199 usada no treino do Módulo 3.2. Resultado contra o modelo fine-tunado publicado no Vertex AI: onze de onze schema válido, cem por cento de precisão média por campo (Módulo 5.1).

#### Passo 2 - A/B contra o genérico

Mesmo conjunto retido, mesmo prompt, contra o gemini-2.5-flash sem ajuste. Sem hint de formato: zero de onze schema válido, o modelo devolve markdown com marcadores em vez de JSON, mesmo entendendo a tarefa. Com hint explícito pedindo JSON válido sem markdown: schema válido quase sempre, mas a precisão média varia entre cinquenta e quatro vírgula cinco e sessenta e seis vírgula sete por cento em execuções reais repetidas (N=20), média de sessenta e um vírgula dois por cento, sempre bem abaixo dos cem por cento do fine-tunado (Módulo 5.2). Fine-tuning ganha na forma e no conteúdo, o genérico com hint só resolve a forma.

#### Passo 3 - Teste de estresse

Round 1, seis documentos escritos à mão, variação de formato (rótulo coloquial, sem "R\$", nome-isca, texto corrido): primeira medição veio oitenta e oito vírgula nove por cento, uma queda de onze vírgula um pontos. Investigando de perto, a causa era um bug de comparação no harness, diferença de maiúscula sendo contada como erro de conteúdo, a mesma lição do normalizarTexto do Módulo 2.2. Corrigido o harness, remedido do zero: seis de seis schema válido, cem por cento, zero queda real (Módulo 5.3).

Round 2, mais severo, variação estrutural (mensagem informal, valor por extenso, duas entidades no mesmo documento): cem por cento de precisão média, zero queda real, em 58 execuções repetidas. Uma checagem inicial com só três chamadas sugeriu um erro de fraseado ("exame de" desaparecendo); repetido em maior escala, o erro não se confirmou, lição sobre tamanho de amostra, não um limite real do piloto. A parte difícil, escolher a entidade certa entre duas, o modelo acertou sempre (Módulo 5.3).

#### Passo 4 - Checklist de graduação e veredito

Cinco critérios definidos antes de checar: baseline maior ou igual a noventa e cinco por cento, bater o genérico em schema e precisão, conjunto generalizar tão bem ou melhor que separado, robustez a formato maior ou igual a noventa e cinco por cento, robustez a estrutura maior ou igual a noventa por cento. Os cinco números medidos acima passam todos os cinco critérios: cinco de cinco, piloto graduado (Módulo 5.4).

Reabrindo o gate de quatro perguntas do Módulo 1.3 com veredito-escala-tool.js: Amplitude Auto, aprovado desde o Módulo 1.3, todas as quatro perguntas verdes. Amplitude Saúde Empresarial, aprovado desde o Módulo 3.2, quando a pergunta três (dado suficiente) cruzou o limiar de zero vírgula três cinco pra zero vírgula seis dois, nove meses de volume real depois. Os dois casos, gate aprovado mais graduação cinco de cinco: veredito, escalar.

Amplitude Atendimento ao Cliente: gate ainda reprovado, pergunta um (zero vírgula três, tarefa aberta) e pergunta quatro (zero vírgula três cinco, política muda rápido demais) continuam vermelhas, sem mudança desde o Módulo 1.3. A evidência de robustez do Módulo 5 nunca testou essa tarefa, então não pode reverter esse veredito: continue prompt mais RAG mais roteamento pra especialista humano.

Fechando uma pergunta técnica pendente desde o Módulo 4.4: rodando `avaliacao_modelo_local_tool.py`, o mesmo conjunto de teste retido contra o modelo local, LoRA rank 8 treinado no Módulo 4.2, também deu onze de onze schema válido, cem por cento de precisão média, o mesmo resultado do Vertex AI. Dois modelos, dois caminhos de treino independentes, mesmo resultado: a robustez não era sorte de um provedor só.

## Nota de curadoria

Reparem no padrão que atravessa os quatro vídeos deste módulo: nenhum número foi aceito na primeira medição. O Módulo 5.1 construiu o teste retido que faltava desde o Módulo 3.2. O Módulo 5.2 comparou contra uma baseline real, não assumida. O Módulo 5.3 quase aceitou uma queda de onze pontos como overfitting real, e só não aceitou porque investigou a causa raiz antes de publicar o número. Este vídeo soma os três resultados num checklist de graduação com limiar explícito e justificado por dificuldade de tarefa, não escondido atrás de intuição.

Ao fazer a atividade de vocês, o ponto não é chegar num piloto perfeito. É notar como cada medição, sozinha, poderia enganar: um teste retido do mesmo gerador de treino parece ótimo e prova pouco; uma comparação sem baseline genérica parece forte e prova pouco; um teste de estresse único, sem investigar a causa da queda, quase virou um alarme falso aqui mesmo. O rigor está em empilhar as medições certas, não em confiar em uma só.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos  
Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager